ACTIVIDAD 5

Materia:	Gestión de Proyectos de Inteligencia Artificial
Actividad:	Actividad 5
Alumno(a):	Katya Márquez Márquez
Matrícula:	7182959
Docente:	Profre: Luis Uriel Vázquez Piña
Fecha de entrega:	17/Octubre/2026

Declaración de Uso de Inteligencia Artificial

El alumno debe indicar de manera honesta si utilizó herramientas de Inteligencia Artificial (IA) para el desarrollo de esta actividad. Completa la siguiente tabla:

Herramienta de IA utilizada	¿La usaste?	Propósito / Descripción de uso
ChatGPT / OpenAI	✓ Sí ☐ No	Complemento de código en python Apoyo en la interpretación de gráficas Información para configuración de MLflow
Claude (Anthropic)	☐ Sí ✓ No	
Gemini (Google)	✓ Sí ☐ No	Primera versión de código en python Información para configuración de MLflow
Copilot (Microsoft)	☐ Sí ✓ No	
Otra (especifica):	☐ Sí ✓ No	

Desarrollo de Contenido

1. Objetivo

Realizar la preparación de los datos, el entrenamiento de un modelo y el registro de los resultados.

2. Reporte técnico

Predicción de Riesgo Patológico

El alcance de este proyecto es construir un sistema automatizado para predecir si una muestra médica presenta riesgo patológico (maligno o benigno) utilizando modelos de Machine Learning.

Se utilizaron los siguientes modelos:
- Regresión Logística
- Random Forest

El proceso de entrenamiento, gráficos y registro del modelo final, se auditó automáticamente utilizando MLflow, con respaldo de la base de datos SQLite **mlflow.db**.

Descripción del conjunto de datos

Para esta actividad se utilizó el conjunto de datos **Breast Cancer Wisconsin (Diagnostic)**, disponible en la biblioteca Scikit-Learn de Python.

El conjunto de datos contiene **569 observaciones y 30 variables predictoras numéricas**, obtenidas mediante el análisis de imágenes digitalizadas de muestras celulares de masas mamarias. Su propósito es identificar patrones que permitan clasificar los tumores como benignos o malignos.

La variable objetivo (**target**) representa el diagnóstico, para esta actividad se estableció **benigno=0 y maligno=1**, con el propósito de considerar los casos malignos como la clase positiva durante la evaluación de los modelos.

El dataset contiene 357 casos benignos y 212 malignos (un total de 569 registros), lo que representa una distribución moderadamente desbalanceada entre ambas clases.

- **Diccionario de datos**

Las 30 variables predictoras describen diez características morfológicas de los núcleos celulares:

Característica	Descripción
Radius	Distancia promedio desde el centro del núcleo hasta su perímetro.
Texture	Variación de la intensidad de los tonos de gris.
Perimeter	Longitud del contorno del núcleo celular.
Area	Superficie del núcleo celular.
Smoothness	Variación local en la longitud del radio.
Compactness	Relación entre el perímetro y el área del núcleo.
Concavity	Grado de concavidad del contorno celular.
Concave points	Cantidad de porciones cóncavas del contorno.
Symmetry	Nivel de simetría del núcleo celular.
Fractal dimension	Medida de la complejidad geométrica del contorno.

Cada característica se representa mediante tres medidas estadísticas; obteniendo las 30 variables utilizadas para entrenar los modelos de clasificación:

mean - valor medio
error - error estándar
worst- promedio de los tres valores más altos

Considerando que todas las variables predictoras son numéricas, no fue necesario aplicar técnicas de codificación de variables categóricas.

- **Supuestos considerados**

Se establecen los siguientes supuestos para el procesamiento y análisis de los datos:

1. Los registros representan observaciones independientes y cuentan con un diagnóstico previamente identificado.
2. Las características morfológicas disponibles contienen información relevante para distinguir entre tumores benignos y malignos.
3. Los valores negativos en las mediciones se consideran inválidos.
4. Los valores iguales a cero se conservan cuando representan mediciones válidas, especialmente en variables relacionadas con la concavidad.
5. Las diferencias de escala entre las variables pueden influir en determinados algoritmos, por lo que se incorpora un proceso de estandarización.
6. La clase maligna se considera positiva para facilitar el análisis de errores de clasificación, especialmente los falsos negativos.
7. Este conjunto de datos tiene fines académicos.

Proceso de limpieza y estandarización

El proceso se desarrolló mediante las bibliotecas Pandas y Scikit-Learn

1. Carga y conservación de los datos originales
Se realizó una carga del dataset y se exportó al archivo **dataset_raw.csv,** con el propósito de conservar la fuente original sin transformaciones.

2. Identificación y eliminación de duplicados
Se identificaron registros idénticos y se utilizó drop_duplicates() para conservar una sola instancia de cada registro. Lo cual previene un entrenamiento incorrecto de los modelos.

3. Revisión de tipos de datos y valores faltantes
Se validó que las 30 variables predictoras correspondieran a valores numéricos. Adicionalmente, se identificaron mediciones negativas y se reemplazaron por valores faltantes **(NaN)**, al considerarse inconsistentes con las características morfológicas analizadas. Los valores iguales a cero se conservan porque pueden representar mediciones correctas.

4. Tratamiento de valores faltantes
Se utilizó **SimpleImputer**, con la estrategia de imputación por mediana, la cual sustituye los valores ausentes por la mediana calculada para cada variable, lo que permite evitar la eliminación de registros (*data leakage*).

5. Estandarización de variables
Se aplicó una transformación mediante **StandardScaler**, para convertir a una escala estandarizada, utilizando su media y desviación estándar: $Z = (X - \mu) / \sigma$

Donde:
- **X:** valor original de la variable.
- **μ:** media de la variable calculada con los datos de entrenamiento.
- **σ:** desviación estándar calculada con los datos de entrenamiento.
- **Z:** valor estandarizado.

La estandarización es importante para el modelo de Regresión Logística, debido a que las diferencias de escala pueden afectar el proceso de optimización y regularización.

En el caso de Random Forest, la estandarización no es indispensable, pero se mantuvo el mismo esquema de preprocesamiento para conservar una estructura uniforme entre los experimentos.

6. Separación de datos para entrenamiento y prueba

80 % para entrenamiento y 20 % para prueba utilizando una semilla aleatoria de 42 para reproducibilidad.

Se aplicó una partición estratificada **(stratify=y)**, con el objetivo de mantener proporciones similares de casos benignos y malignos en ambos conjuntos.

Durante la optimización de los modelos se utilizó validación cruzada estratificada de cinco particiones, lo que permitió evaluar diferentes configuraciones de hiperparámetros de manera sistemática.

Estrategia de versionamiento

Se conservan dos versiones del conjunto de datos:

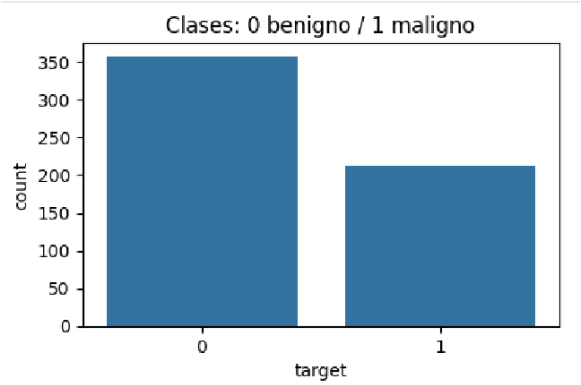
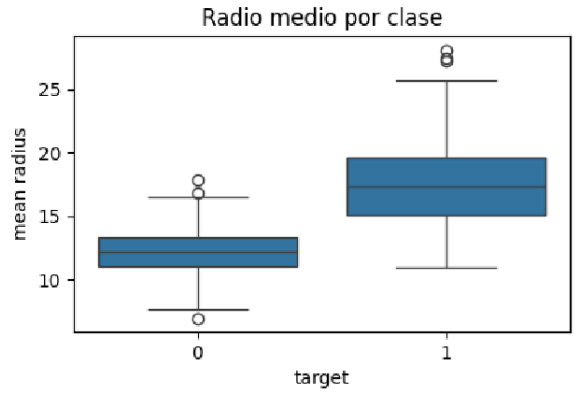
- dataset_raw.csv: conjunto de datos original
- dataset_cleaned.csv: conjunto de datos después de las reglas de limpieza

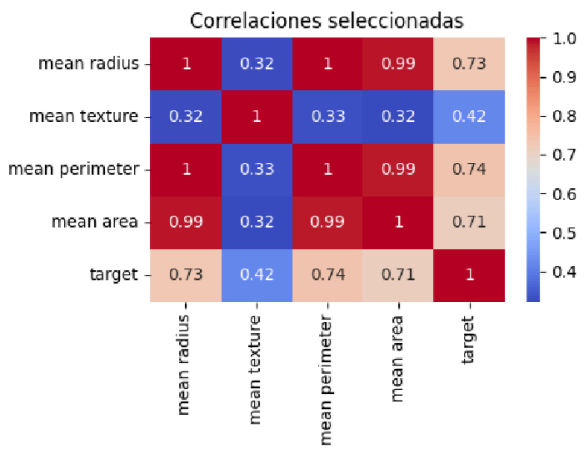
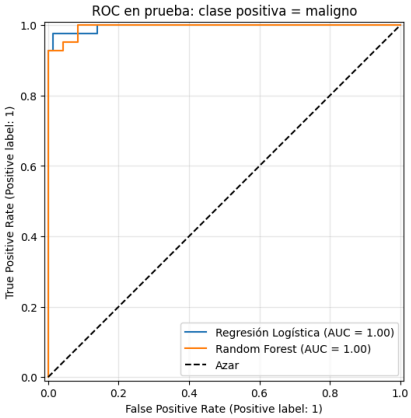
Generación de archivo CHANGELOG.md para documentar las principales modificaciones realizadas y se calculó una huella digital SHA-256 del dataset preparado.

Este identificador permite reconocer la versión específica de los datos utilizada en los experimentos y facilita su asociación con los resultados registrados en MLflow.

Visualizaciones relevantes (identificación de patrones y anomalías)

Se generaron visualizaciones para identificar patrones, relaciones entre variables y posibles valores atípicos en el conjunto de datos.Asimismo, se utilizaron curvas ROC para comparar la capacidad predictiva de los modelos de Regresión Logística y Random Forest.

	Interpretación
	La distribución de clases muestra que el 62.7 % de las observaciones corresponde a tumores benignos y el 37.3 % a tumores malignos. Esta diferencia representa un desbalance moderado entre las clases, por lo que se utilizó una separación estratificada de los datos y métricas complementarias a la exactitud, como recall y F1-score, para evaluar adecuadamente el desempeño de los modelos.
	Se muestra que los tumores malignos presentan, en general, valores superiores a los benignos, así como una mayor dispersión. También se identificaron observaciones fuera de los límites habituales de ambas distribuciones, consideradas valores atípicos desde el punto de vista estadístico. Estos valores no se eliminaron, ya que pueden representar características celulares legítimas y aportar información relevante para la clasificación. La superposición entre ambas clases demuestra la necesidad de utilizar variables predictoras.

	La matriz permite identificar asociaciones positivas entre las variables **mean radius, mean perimeter** y **mean area**, con coeficientes cercanos a 0.99 y 1.00. Este comportamiento refleja la relación geométrica entre las dimensiones del núcleo celular. Asimismo, las variables presentan correlaciones positivas con el diagnóstico maligno, aproximadamente entre 0.71 y 0.74, lo que permite distinguir entre las clases. Las correlaciones elevadas entre variables predictoras también evidencian una posible multicolinealidad.
	Las curvas ROC muestran que ambos modelos presentan alta capacidad discriminativa, con valores de AUC cercanos a 1.00. Las curvas se ubican próximas a la esquina superior izquierda, lo que indica un desempeño favorable en la identificación de casos malignos con tasas bajas de falsos positivos. Las diferencias entre los modelos son pequeñas, por lo que la selección final debe considerar también otras métricas, como recall, F1-score, y el costo de los errores de clasificación.

Descripción de los modelos entrenados

Se entrenaron dos modelos de aprendizaje supervisado: Regresión Logística y Random Forest, con el objetivo de clasificar tumores mamarios como benignos o malignos utilizando las 30 características del dataset.

Regresión Logística: algoritmo de clasificación que estima la probabilidad de que un tumor sea maligno a partir de sus características celulares. Destaca por su eficiencia computacional, facilidad de interpretación y capacidad para identificar relaciones lineales entre variables.

Random Forest: algoritmo que combina múltiples árboles de decisión para generar predicciones más robustas. Permite identificar relaciones complejas y no lineales entre las variables, reduciendo el riesgo de sobreajuste.

Ambos modelos se entrenaron utilizando el 80 % de los datos y se evaluaron con el 20 %. Se aplicó GridSearchCV con validación cruzada de cinco particiones para optimizar sus hiperparámetros.

Configuración de hiperparámetros

Para optimizar el desempeño de los modelos, se utilizó **GridSearchCV con validación cruzada estratificada de cinco particiones (StratifiedKFold)**. Se selecciona **F1-score** como métrica de optimización seleccionada, debido a que permite equilibrar la precisión (*precision*) y la sensibilidad (*recall*) en la identificación de tumores malignos.

Los hiperparámetros evaluados fueron los siguientes:

Modelo	Hiperparámetro	Valores evaluados	Valores evaluados
Regresión Logística	C	0.01, 0.1, 1.0, 10.0	Para controlar la intensidad de la regularización y reducir el riesgo de sobreajuste.
Regresión Logística	penalty	L2	
Regresión Logística	solver	lbfgs	
Random Forest	n_estimators	50, 100, 200	Se evaluaron diferentes cantidades de árboles, profundidades máximas y números mínimos de muestras para dividir un nodo, buscando equilibrar la capacidad predictiva y la complejidad del modelo.
Random Forest	max_depth	None, 5, 10	
Random Forest	min_samples_split	2, 5	

Se evaluaron **4 combinaciones para Regresión Logística y 18 para Random Forest**, utilizando cinco particiones de validación cruzada. Se estableció una semilla aleatoria de 42 para favorecer la reproducibilidad.

Los hiperparámetros seleccionados y los resultados obtenidos se registraron en MLflow para facilitar su comparación y trazabilidad.

Métricas obtenidas

Métrica	Regresión Logística	Random Forest	Descripción
Accuracy (Exactitud)	96.49%	97.37%	Porcentaje total de diagnósticos correctos
Precision (Precisión)	97.50%	100.00%	Malignos clasificados correctamente
Recall (Sensibilidad)	92.86%	92.86%	De todos los casos malignos reales, cuántos logró detectar el modelo
F1-Score	95.12%	96.30%	Balance óptimo entre Precisión y Recall
ROC-AUC	99.60%	99.50%	Capacidad del modelo para separar pacientes sanos de enfermos
F1 Promedio en CV	96.40%	95.53%	Rendimiento promedio durante la validación cruzada ($k = 5$)

Comparación estadística de resultados

Random Forest presentó resultados ligeramente superiores en accuracy, precision y F1-score, mientras que Regresión Logística obtuvo un ROC-AUC ligeramente mayor. Ambos modelos alcanzaron el mismo recall (0.9286), lo que indica una capacidad similar para identificar los casos malignos en el conjunto de prueba.

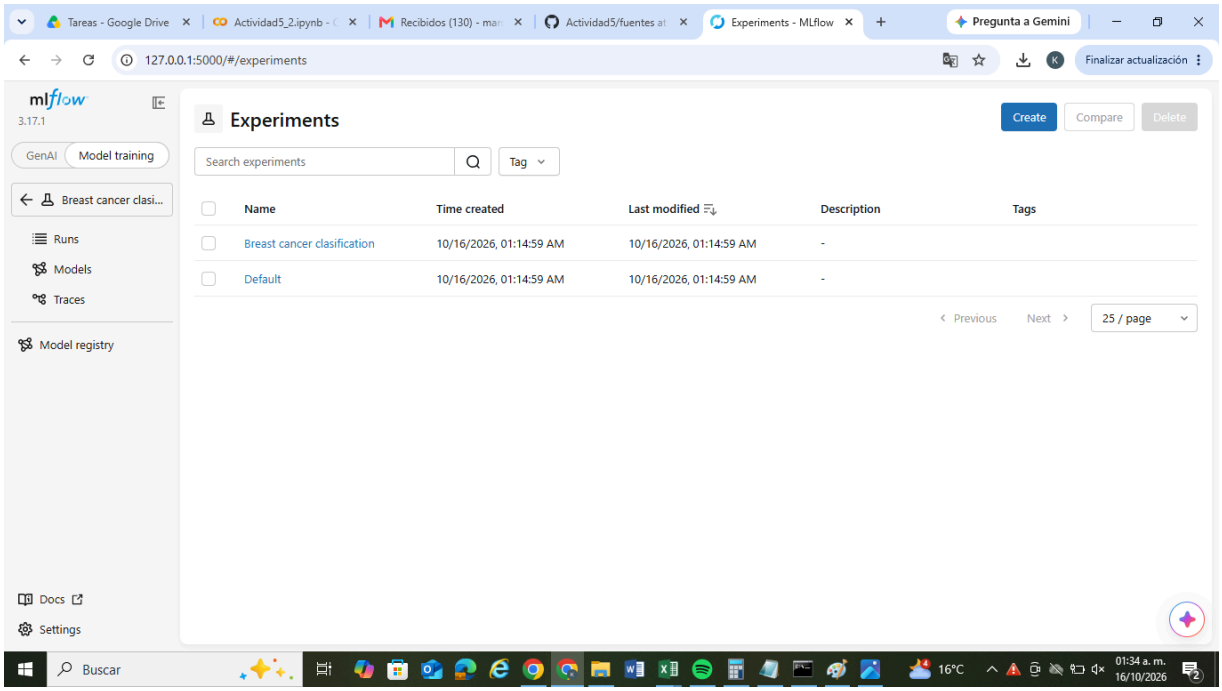
Para determinar si las diferencias observadas eran estadísticamente significativas, se aplicaron dos pruebas sobre las puntuaciones de validación cruzada:

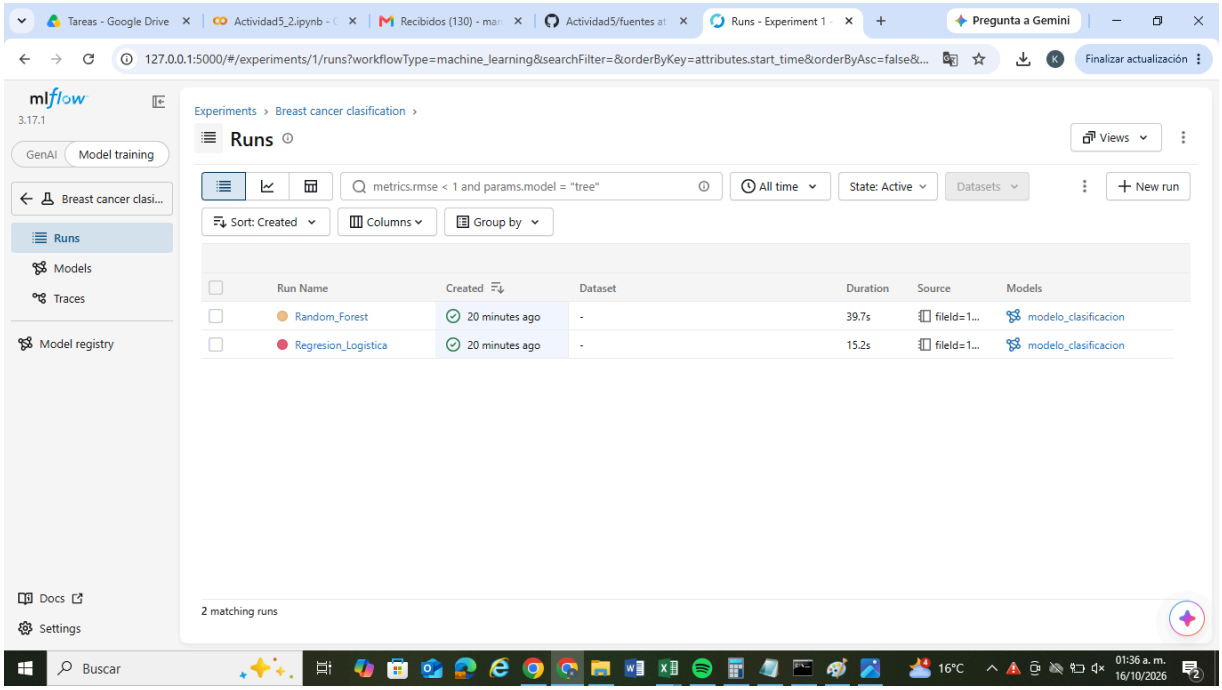
Prueba estadística	Valor p
Prueba t pareada	0.3064
Prueba de Wilcoxon	0.4375

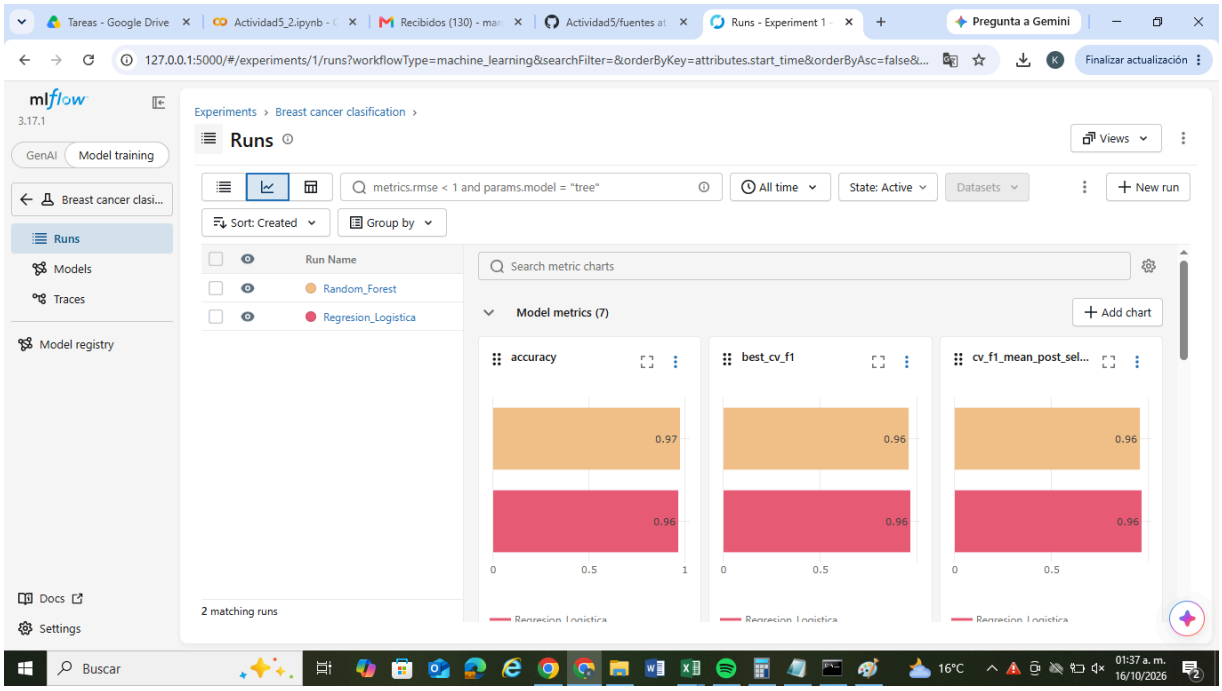
En ambas pruebas se obtuvieron valores p superiores al nivel de significancia establecido (α = 0.05). Por lo tanto, **no se encontró evidencia estadística suficiente para afirmar que existe una diferencia significativa en el desempeño de ambos modelos.**

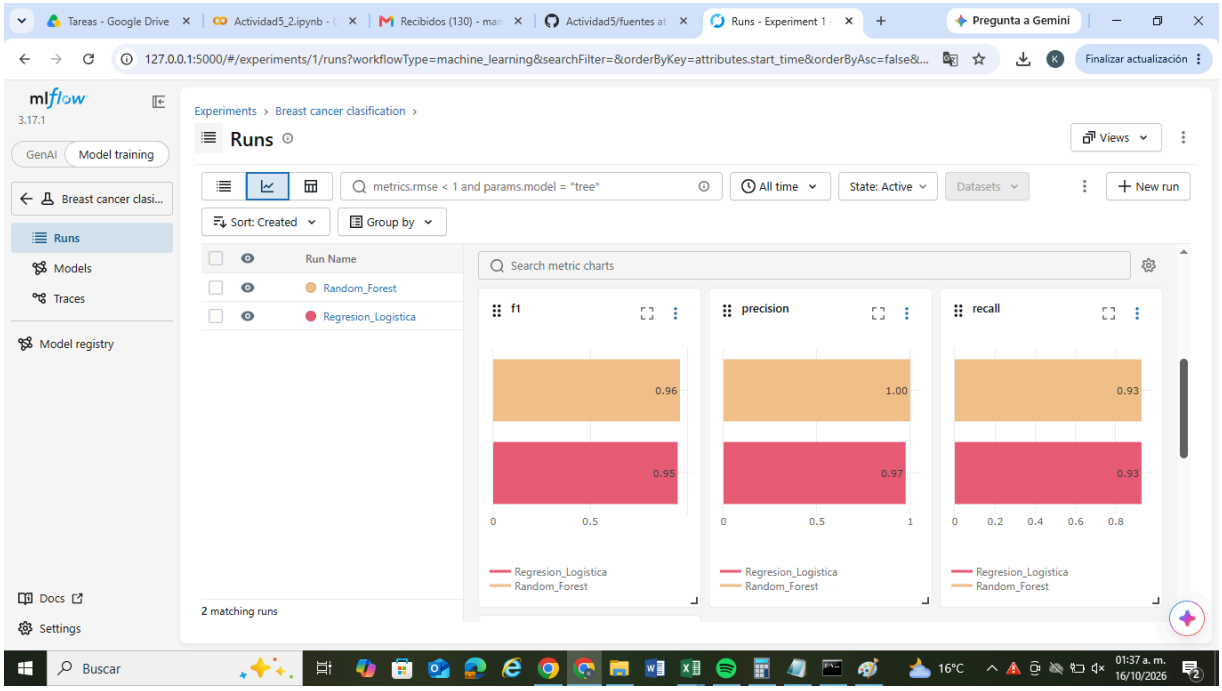
Estos resultados sugieren que los dos algoritmos presentan un desempeño comparable. Aunque Random Forest obtuvo mejores resultados puntuales en algunas métricas, Regresión Logística representa una alternativa competitiva por su menor complejidad y mayor facilidad de interpretación.

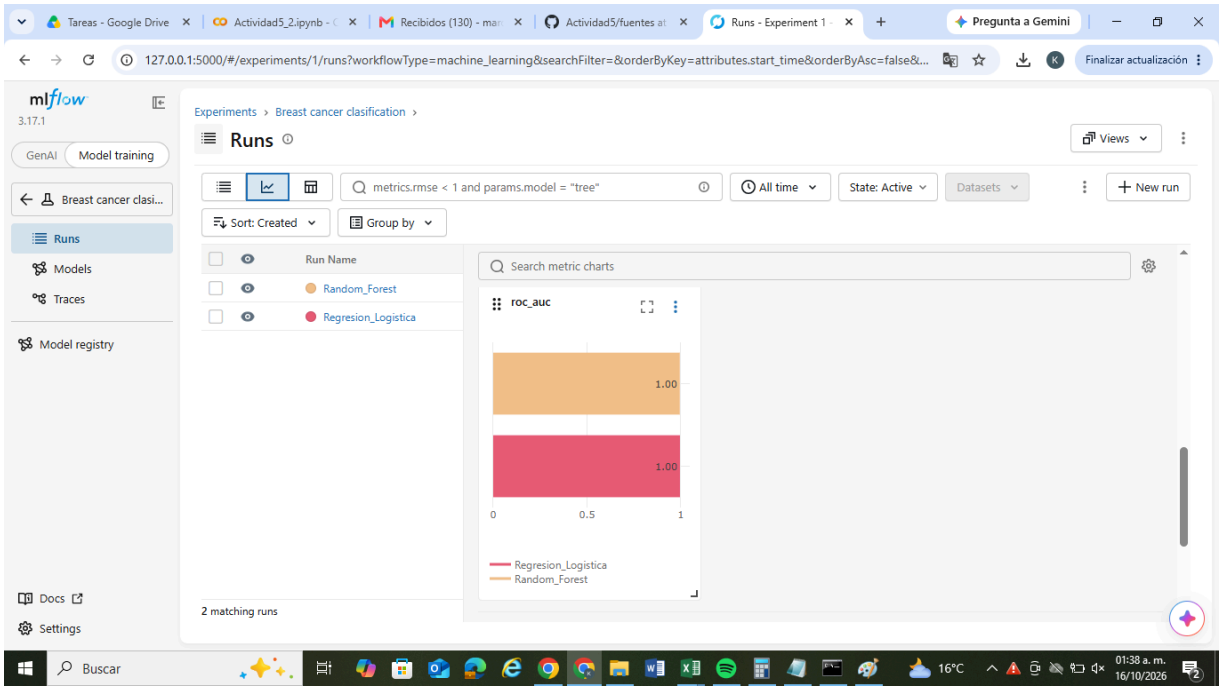
Evidencia de uso de MLflow

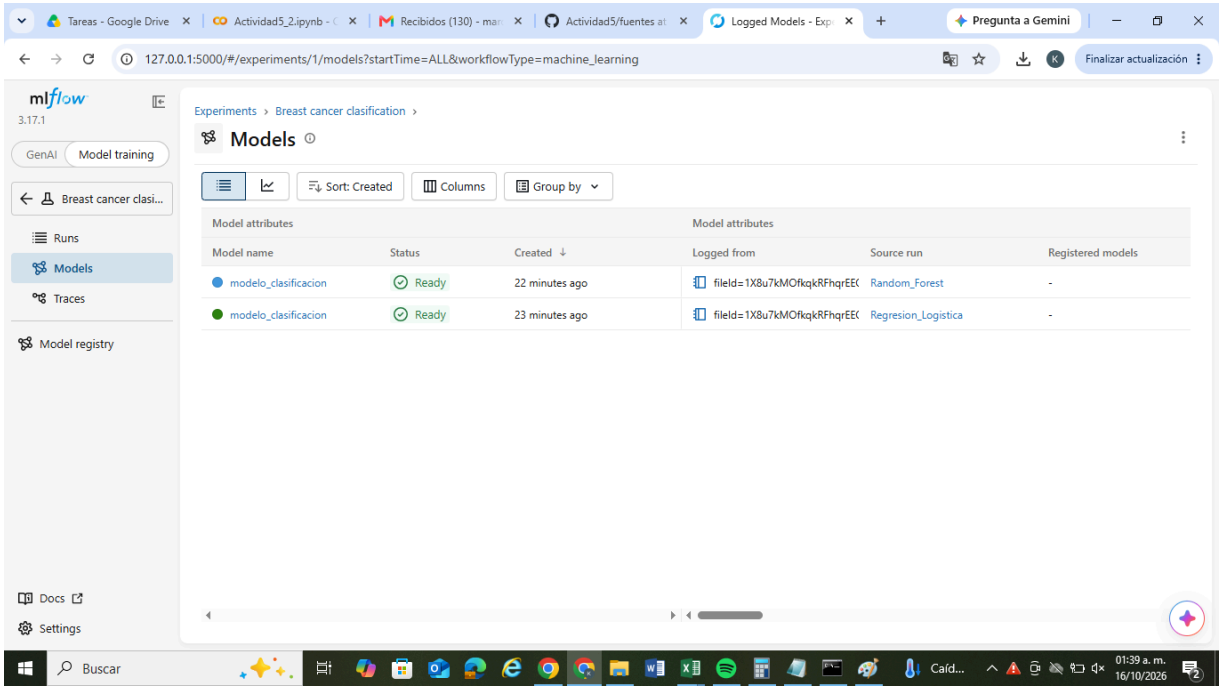





Runs - Experiment 1
127.0.0.1:5000/#/experiments/1/runs?workflowType=machine_learning&searchFilter=&orderByKey=attributes.start_time&orderByAsc=false&...
mlflow
3.17.1
Experiments › Breast cancer clasification ›
Runs
Views
GenAI
Model training
Breast cancer clasi...
Runs
Models
Traces
Model registry
metrics.rmse < 1 and params.model = "tree"
All time
State: Active
Datasets
New run
Sort: Created
Group by
Run Name
Random_Forest
Regresion_Logistica
Search metric charts
Model metrics (7)
Add chart
accuracy
best_cv_f1
cv_f1_mean_post_sel...
0.97
0.96
0.96
0.96
0.96
0.96
0
0.5
1
2 matching runs
Docs
Settings
Buscar
16°C
01:37 a. m.
16/10/2026


Runs - Experiment 1
127.0.0.1:5000/#/experiments/1/runs?workflowType=machine_learning&searchFilter=&orderByKey=attributes.start_time&orderByAsc=false&...
mlflow
3.17.1
Experiments › Breast cancer clasification ›
Runs
Views
GenAI
Model training
Breast cancer clasi...
Runs
Models
Traces
Model registry
metrics.rmse < 1 and params.model = "tree"
All time
State: Active
Datasets
New run
Sort: Created
Group by
Run Name
Random_Forest
Regresion_Logistica
Search metric charts
f1
precision
recall
0.96
0.95
1.00
0.97
0.93
0.93
0
0.5
1
0.2
0.4
0.6
0.8
Regresion_Logistica
Random_Forest
2 matching runs
Docs
Settings
Buscar
16°C
01:37 a. m.
16/10/2026


Runs - Experiment 1
127.0.0.1:5000/#/experiments/1/runs?workflowType=machine_learning&searchFilter=&orderByKey=attributes.start_time&orderByAsc=false&...
mlflow
3.17.1
GenAI
Model training
Breast cancer clasi...
Runs
Models
Traces
Model registry
Docs
Settings
Experiments › Breast cancer clasification ›
Runs
Views
metrics.rmse < 1 and params.model = "tree"
All time
State: Active
Datasets
New run
Sort: Created
Group by
Run Name
Random_Forest
Regresion_Logistica
Search metric charts
roc_auc
1.00
1.00
0
0.5
1
Regresion_Logistica
Random_Forest
2 matching runs
Buscar
16°C
01:38 a. m.
16/10/2026


Logged Models - Exp
127.0.0.1:5000/#/experiments/1/models?startTime=ALL&workflowType=machine_learning
mlflow
3.17.1
GenAI
Model training
Breast cancer clasi...
Runs
Models
Traces
Model registry
Docs
Settings
Experiments › Breast cancer clasification ›
Models
Sort: Created
Columns
Group by
Model attributes
Model attributes
Model name
Status
Created
Logged from
Source run
Registered models
modelo_clasificacion
Ready
22 minutes ago
fileId=1X8u7kMOfkqkRFhqrEE(
Random_Forest
-
modelo_clasificacion
Ready
23 minutes ago
fileId=1X8u7kMOfkqkRFhqrEE(
Regresion_Logistica
-
Buscar
01:39 a. m.
16/10/2026

Deuda técnica y MLOps

Deuda Técnica: Existe el riesgo de que el modelo pierda precisión con el tiempo si cambian las tecnologías de tomografía o biopsia (*Data Drift*). Se recomienda programar revisiones periódicas de los datos de entrada.

Por su parte, **MLOps** ayuda a mejorar la organización y el mantenimiento de los modelos mediante buenas prácticas, como guardar versiones de los datos, automatizar procesos y revisar periódicamente su desempeño.

Conclusiones

En esta actividad se logró entrenar y comparar dos modelos de Machine Learning, Regresión Logística y Random Forest, para clasificar tumores mamarios como benignos o malignos.

Ambos modelos obtuvieron resultados satisfactorios, destacando Random Forest con un desempeño ligeramente superior en algunas métricas. Sin embargo, las pruebas estadísticas no mostraron diferencias significativas entre ambos modelos.

El uso de MLflow permitió registrar los experimentos, parámetros, métricas y modelos, facilitando la comparación y trazabilidad de los resultados.

Finalmente, se comprobó la importancia de preparar correctamente los datos, optimizar los modelos y aplicar buenas prácticas de MLOps para desarrollar soluciones confiables, reproducibles y fáciles de mantener.

Referencias

MLflow. (s. f.). *MLflow tracking*. https://mlflow.org/docs/latest/tracking/

MLflow. (s. f.). *Tracking experiments with a local database*. https://mlflow.org/docs/latest/ml/tracking/tutorials/local-database/

Scikit-learn developers. (s. f.). *GridSearchCV*. Scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html

Scikit-learn developers. (s. f.). *Pipeline*. Scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.pipeline.Pipeline.html

Scikit-learn developers. (s. f.). *sklearn.datasets.load_breast_cancer*. Scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_breast_cancer.html

Scikit-learn developers. (s. f.). *StratifiedKFold*. Scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.StratifiedKFold.html

Wolberg, W., Mangasarian, O., Street, N., & Street, W. (1993). *Breast Cancer Wisconsin (Diagnostic)* [Conjunto de datos]. UCI Machine Learning Repository. https://doi.org/10.24432/C5DW2B